Rubyによるデータ解析

Data Analysis in Ruby

2016年2月19日

株式会社ネットワーク応用通信研究所　前田　修吾

NaCl

NaCl

自己紹介

- **名前**
  - 前田 修吾
- **所属**
  - 株式会社ネットワーク応用通信研究所（1999年～）
  - 一般財団法人Rubyアソシエーション（2007年～）
- **オープンソース活動**
  - Ruby開発者（1997年～）

NaCl

本日のテーマ

- **Rubyによるデータ解析**

データ解析の例

NaCl

株式市場のブラウン運動

- M. F. M. Osborne, *Brownian Motion in the Stock Market*, Operations Research, 1959
- 『ウォール街の物理学者』という書籍で紹介
- 株価の対数とブラウン運動における微粒子の座標との類似性
- 統計力学的手法を株価に適用

NaCl

ブラウン運動

- 液体のような溶媒中に浮遊する微粒子が不規則に運動する現象

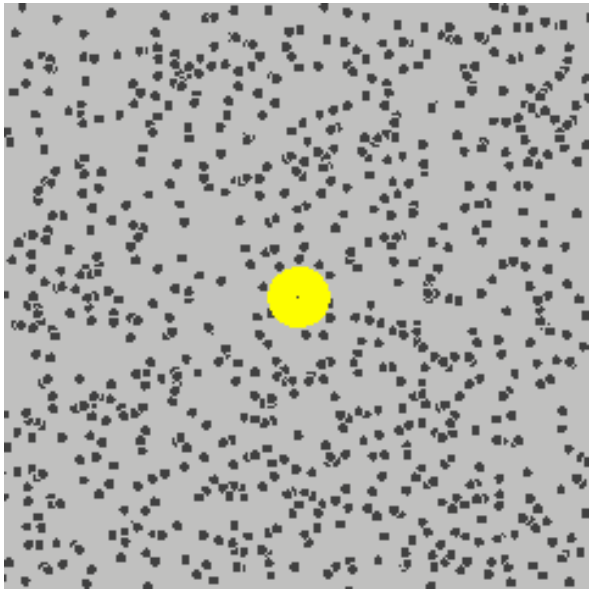

https://commons.wikimedia.org/wiki/File:Brownian_motion_large.gif CC-BY-SA 3.0 by Lookang

NaCl

1. 株価の変化

- 株価の変化は離散的（1/8ドル単位）
- 株価の対数も同じ

NaCl

2. 取引数

- **単位時間あたりに有限の取引（あるいは決定）が行われる**
  - 一つの株に対して0～1000あるいはそれ以上

NaCl

3. Weber-Fechnerの法則

- **精神物理学の基本法則**
- **感覚量Eは刺激量の強度Rの対数に比例する**
  - $E = C \log R$
  - 強度100の刺激が200に増加した場合の感覚量と、
    強度200の刺激が400に増加した場合の感覚量は同じ
- **株価という刺激とそれに対するトレーダー・投資家の主観的感覚は
  この法則に従うと仮定する**

NaCl

統計学的アプローチ

- **金融の知識のない統計学者がNY市場の取引データを分析したら？**
  - 集団が均質かどうか
  - 各属性・変数の関連性

NaCl

株価の分布

- 株価の終値を主要な変数と推測
- 1000要素のサンプルの分布をプロット

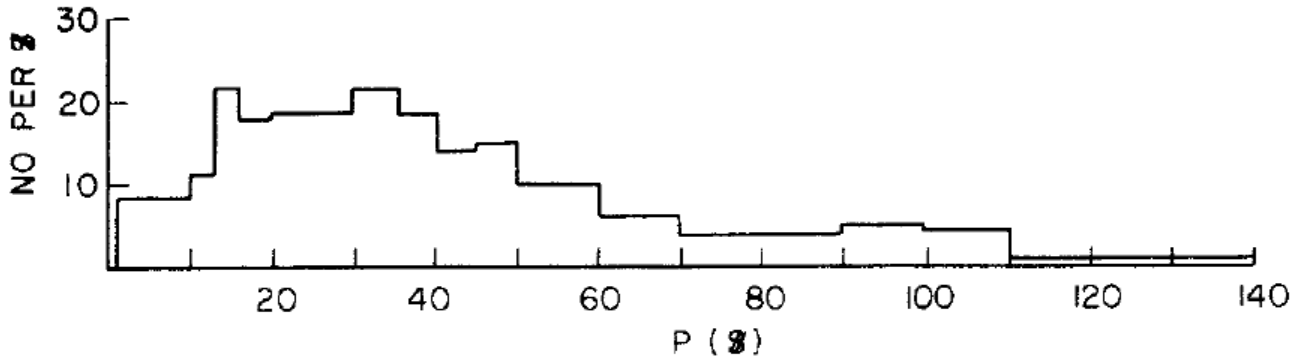

Fig 1 Distribution function of closing prices for July 31, 1956 (all items, NYSE)

- 株価は正規分布に従わない
- 株価の対数は正規分布に従うかもしれない

NaCl

正規分布

- **以下の確率密度関数を持つ**
  - $f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$
- **確率密度関数**
  - xの範囲の面積 = 確率
- **サンプルサイズを大きくすると標本平均が真の平均に近づく（大数の法則）**

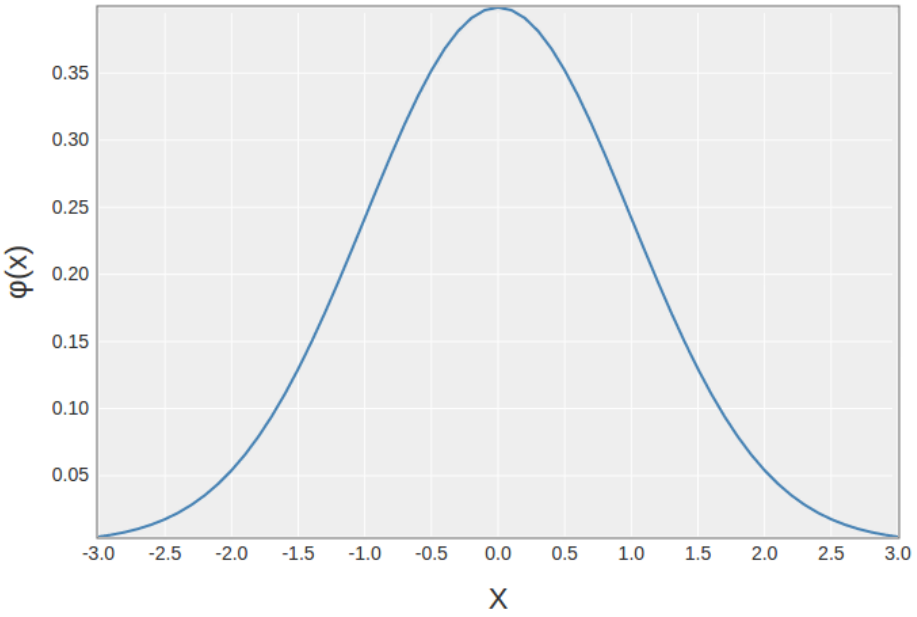

NaCl

平均・分散・標準偏差

- **平均**
  - $\mu = \frac{1}{n}\sum_{i=1}^{n} x_i$
- **分散**
  - 平均からのばらつきの指標（正の値にするため自乗誤差を使う）
  - $\sigma^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \mu)^2$
- **標準偏差**
  - 分散の平方根（x_iやμの値と比較しやすくするため平方根を取る）
  - $\sigma = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \mu)^2}$

NaCl

株価の対数の分布

- **正規分布ではない**
- **$\log_e P \approx 45$周辺の副極大**
  - この集団は均質でない
  - 少なくとも二つの下位集団
- **生データの確認**
  - **$\log_e P \approx 45$**周辺のデータに pfd (preferred) 属性

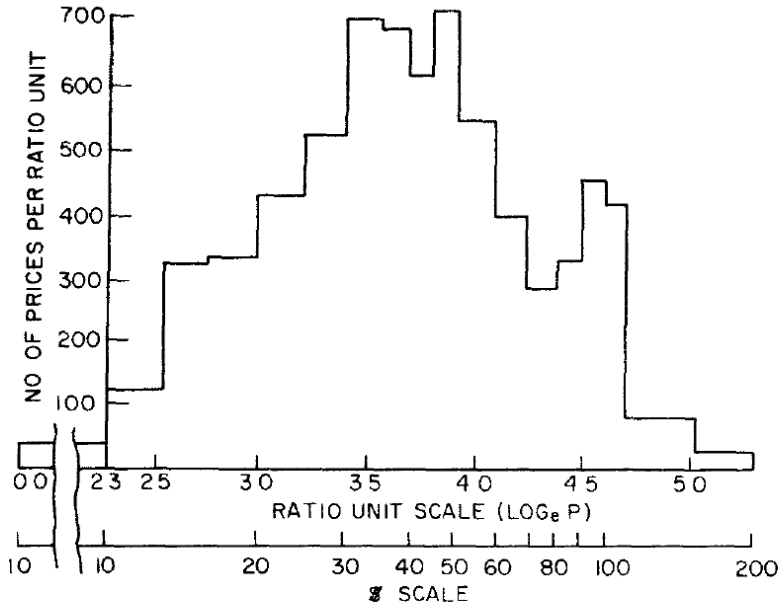

Fig 2 Distribution function for $\log_e P$ on July 31, 1956 (all items NYSE)

NaCl

対数収益率を使う根拠

- 価格の変化と利益・損失に対する主観的感覚を表す
- $10から$11の価格変化と、$100から$110の価格変化に対する主観的感覚は同じ
- なぜ収益率 $\frac{P(t+\tau)-P(t)}{P(t)}$ ではなく対数収益率 $\log_e \frac{P(t+\tau)}{P(t)}$ を使うか
- 対数収益率を使うことで、上昇率と下降率の対称性が得られる
  - 価格が $\frac{1}{2}$ 下降した後に $\frac{1}{2}$ 上昇しても元の価格に戻らない
  - $\log_e \frac{1}{2} = -\log_e 2$

NaCl

4. 論理的決定

- **収益の期待値**
  - Aという一連の行動がY_{A1}, Y_{A2}という収益を確率$\varphi(Y_{A1})$, $\varphi(Y_{A2})$で生む
  - Bという一連の行動についても同様に考える
  - 収益の期待値 $\varepsilon(Y_A) = \sum_i Y_{Ai}\varphi(Y_{Ai})$
- **収益の期待値が高い行動を選択**
  - $\varepsilon(Y_A)$ と$\varepsilon(Y_B)$ のどちらが大きいか？
- **価格$P_0(t)$の株を100株買うかどうか？**
  - A = 将来 $t+\tau$ に株を売るために買う
  - B = 買わない
  - $Y_A(\tau) = \Delta\log_e[100\ P(t)] = \log_e[P(t+\tau)/P_0(t)]$
  - $Y_B = 0$
  - $Y_A(\tau)$の期待値の見積が正か負かによって論理決定を行う

NaCl

5. 市場の平等性

- **$\Delta\log_e P$ を買い手は正、売り手は負と判断する**
  - $\mathrm{E}\varepsilon(\Delta\log_e P)_{\mathrm{S}} + \mathrm{E}\varepsilon(\Delta\log_e P)_{\mathrm{B}} = 0$
    - ここで P は1株当たりの価格、$\mathrm{E}\varepsilon$ は期待値の見積である
- **市場全体では以下の式のような状況**
  - $\mathrm{E}\varepsilon(\Delta\log_e P)_{\mathrm{M=S+B}} = 0$
  - 上記の式では見積を表す E はなくてもよいかもしれない

NaCl

6. 株価の収益率の分布

- **以下の $Y(\tau)$ は、平均 0、標準偏差 $\sigma_{Y(\tau)}$ の正規分布に従うと予測される**
  - $Y(\tau) = \log_e[P(t+\tau)/P_0(t)]$
- **$\sigma_{Y(\tau)}$ は取引数の平方根に比例する**
- **取引数が時間上均一に分布すると考えると**
  - $\sigma_{Y(\tau)}$ は時間間隔の平方根に比例する
  - すなわち、$\sigma_{Y(\tau)}$ は $\sigma\sqrt{\tau}$ という形式となる

NaCl

7. 数学的表現

- **k 個のランダムな独立変数 $y(i) = i, \cdots, k$ を仮定する**
  - $y(i) = \Delta_{i\delta} \log_e P = \log_e [P(t + i\delta)/P(t + \{i - 1\}\delta)]$
    - ここで、$P(t)$ はある銘柄の時間 t における価格、δ は取引間の小さな時間間隔である
    - $y(i)$ は同じ標準偏差$\sigma(i) = \sigma'$ を持つと仮定する
- **k 回の取引、$\tau = k\delta$ 時間後の $Y(\tau)$ を以下のように定義する**
  - $Y(\tau) = Y(k\delta) = \sum_{i=1}^{i=k} y(i) = \log_e [P(t + \tau)/P(t)] = \Delta_\tau \log_e P(t)$
- **Yの標準偏差**
  - $\boldsymbol{\sigma}_{Y(\tau)} = \sqrt{\varepsilon(Y^2) - [\varepsilon(Y)]^2} = \sqrt{\sum_{i=1}^{i=k} \sigma^2(i)} = \sqrt{k}\sigma' = \sqrt{\tau \,/\, \delta}\sigma'$
- **中心極限定理により、$y(i)$ の分布によらず k が大きくなると $Y(\tau)$ は正規分布に近づく**

NaCl

観測データとの比較

- 論文のデータについては省略
- 後でRubyでやってみる

NaCl

収益率の分布の非正規性

- **Benoit Mandelbrot, *The Variation of Certain Speculative Prices*, Jounal of Business, 1963**
- **Benoit Mandelbrot, *The Variation of Other Speculative Prices*, Jounal of Business, 1967**
- **収益率の分布は、安定分布だが正規分布ではない**
- **安定分布は α というパラメータで分布の裾の広さが決まる**
  - 小さいほど裾が広い（正規分布は$\alpha = 2$）
  - $\alpha \leq 1$ の場合、大数の法則に従わない
  - $\alpha < 2$ の場合、中心極限定理は成り立たない
- **Mandelbrotは収益率は $1 < \alpha < 2$ の安定分布に従うと考えた**

NaCl

安定分布のPDFとCDF

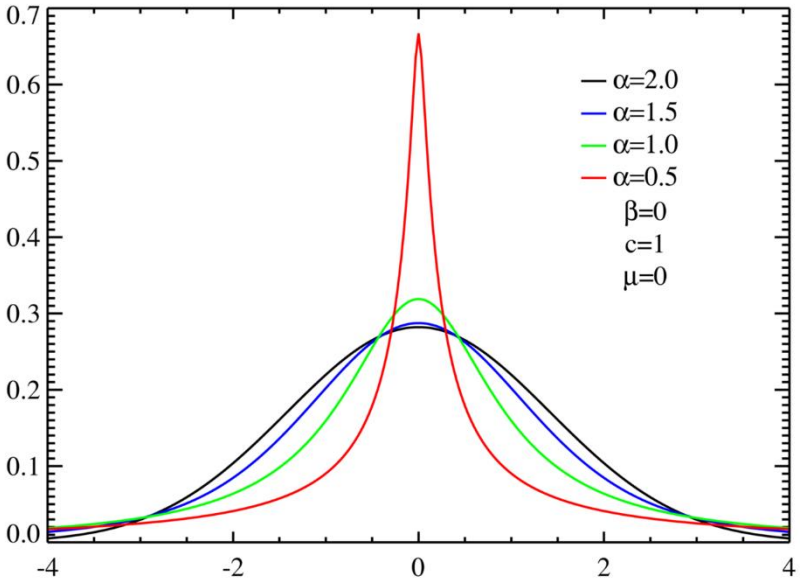

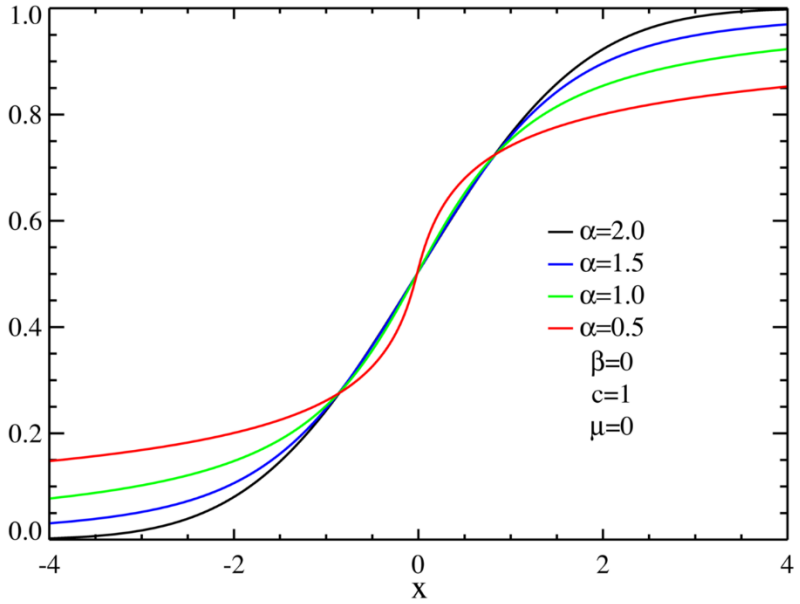

左: 安定分布の確率密度関数
https://commons.wikimedia.org/wiki/File:Levy_distributionPDF.png public domain by PAR
右: 安定分布の累積分布関数
https://commons.wikimedia.org/wiki/File:Levy_distributionCDF.png CC-BY-SA 3.0 by PAR

Rubyによるデータ解析の現状

NaCl

Why Ruby?

- **Pythonと同じ理由（『Pythonによるデータ分析入門』）**
  - 「糊（グルー）」としてのRuby
    - C/C++/FORTRANなどで書かれたコードをつなぎ合わせる
  - 「2つの言語を利用する」ことの問題を解決する
    - アプリケーション開発とデータ解析で同じ言語を使う

NaCl

ライブラリ・ツール群

分類	Python	Ruby
ベクトル・行列	NumPy	NArray, NMatrix
データフレーム	pandas	daru
可視化	matplotlib	Nyaplot
対話環境	Jupyter/IPython	Jupyter/IRuby
科学計算全般	SciPy	SciRuby

NaCl

NArray

- 多次元配列ライブラリ
- 連続したメモリ領域に要素を配置し、次元毎の要素数を固定することでインデックスアクセスを行う
  - `4 × 3`の多次元配列`a`のとき、`a[i, j]` は `i + 4 * j` 番目

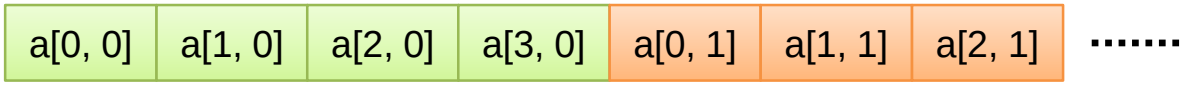

  - 次元順序は次期開発版で変更？
- 多次元配列同士の演算、多次元配列とスカラー値の演算が高速
- 最新リリースは2013年2月27日
  - 別リポジトリで次期開発版が開発中

NaCl

NMatrix

- **SciRubyプロジェクトの行列計算ライブラリ**
- **NArrayより後発の競合ライブラリ**
  - 同時に使えないという意味でも競合…
    - ドキュメントには `require "nmatrix/nmatrix"` で回避せよとあるが、その後で `require "narray"` しているライブラリがあるとエラー…

NaCl

daru

- **Data Analysis in RUby**
- **Daru::Vector**
  - 一次元ベクトルを表すデータ構造
- **Daru::DataFrame**
  - スプレッドシートライクな二次元の表を表すデータ構造

NaCl

Daru::Vector

- 1次元ベクトル

```
v1 = Daru::Vector.new([40, 20, 30])
v2 = Daru::Vector.new([10, 60, 30])
v1 + v2 #=> Vector[50, 80, 60]
v1 * 10 #=> Vector[400, 200, 300]
v1.mean #=> 30.0
```

NaCl

Daru::DataFrame

- 2次元のスプレッドシート風データ構造

```
df = Daru::DataFrame.new(x: [1,2,3], y: [4,5,6])
```

- 各列がDaru::Vectorによって表現される
- 列単位の処理は速いが、行単位の処理は遅い
  - とくに遅い例

```
df.filter_rows {|row| row[:x] > 1}
```

  - 高速化例

```
df.where(df[:x].gt(1))
```

NaCl

Nyaplot

- プロットライブラリ
- Jupyter notebook上で動作
- WebGLを利用した3Dプロットも可能
- 散布図のプロット例

```
plot = Nyaplot::Plot.new
sc = plot.add(:scatter, [0,1,2,3,4], [-1,2,-3,4,-5])
plot.show
```

NaCl

Jupyter/IRuby

- **Jupyter**
  - Webアプリケーションによる対話環境
  - Mathematica風のノートブック
    - プログラムの対話的実行
    - グラフの描画
  - プログラミング言語非依存
    - 各言語の実行環境をカーネルとして提供
    - プロセス間通信
- **IRuby**
  - Jupyter用のRubyカーネル

NaCl

SciRuby

- Ruby用の科学計算ライブラリの開発プロジェクト
- NMatrix, daru, IRuby, NyaplotもSciRubyの一部
- Statsample
  - 統計用ライブラリ
- Distribution
  - 確率分布用ライブラリ

NaCl

デモ

- **株価データの解析**
  - https://github.com/shugo/DCW2016/blob/master/Stock.ipynb
- **PSDSから取得したデータの解析**
  - https://github.com/shugo/DCW2016/blob/master/PSDS.ipynb

今後の課題

NaCl

利用促進

- **現状は利用者が少ない**
  - RubyKaigiでデータ解析分野の発表は0
  - nmatrixとstatsampleを同時にrequireすると最新のRubyではエラーになる
- **今後の方策**
  - ドキュメントの充実
  - 利用事例の発信

NaCl

機能追加・機能改善

- **Python/R等に比べ機能的に見劣りする**
  - 欠損値の扱い
    - チェックや穴埋め
  - 時系列データの扱い
    - 再サンプリング
  - 金融関係の機能
  - 経験累積分布
  - Q-Qプロット
  - …

NaCl

性能改善

- NMatrixは遅い
- ベンチマークプログラム

```
m = NMatrix.dindgen([100000])
a = 0.0.step(99999.0, 1.0).to_a

Benchmark.bmbm do |x|
  x.report("NMatrix") do
    m.mean
  end

  x.report("Array") do
    a.sum.quo(a.size)
  end
end
```

NaCl

ベンチマーク結果

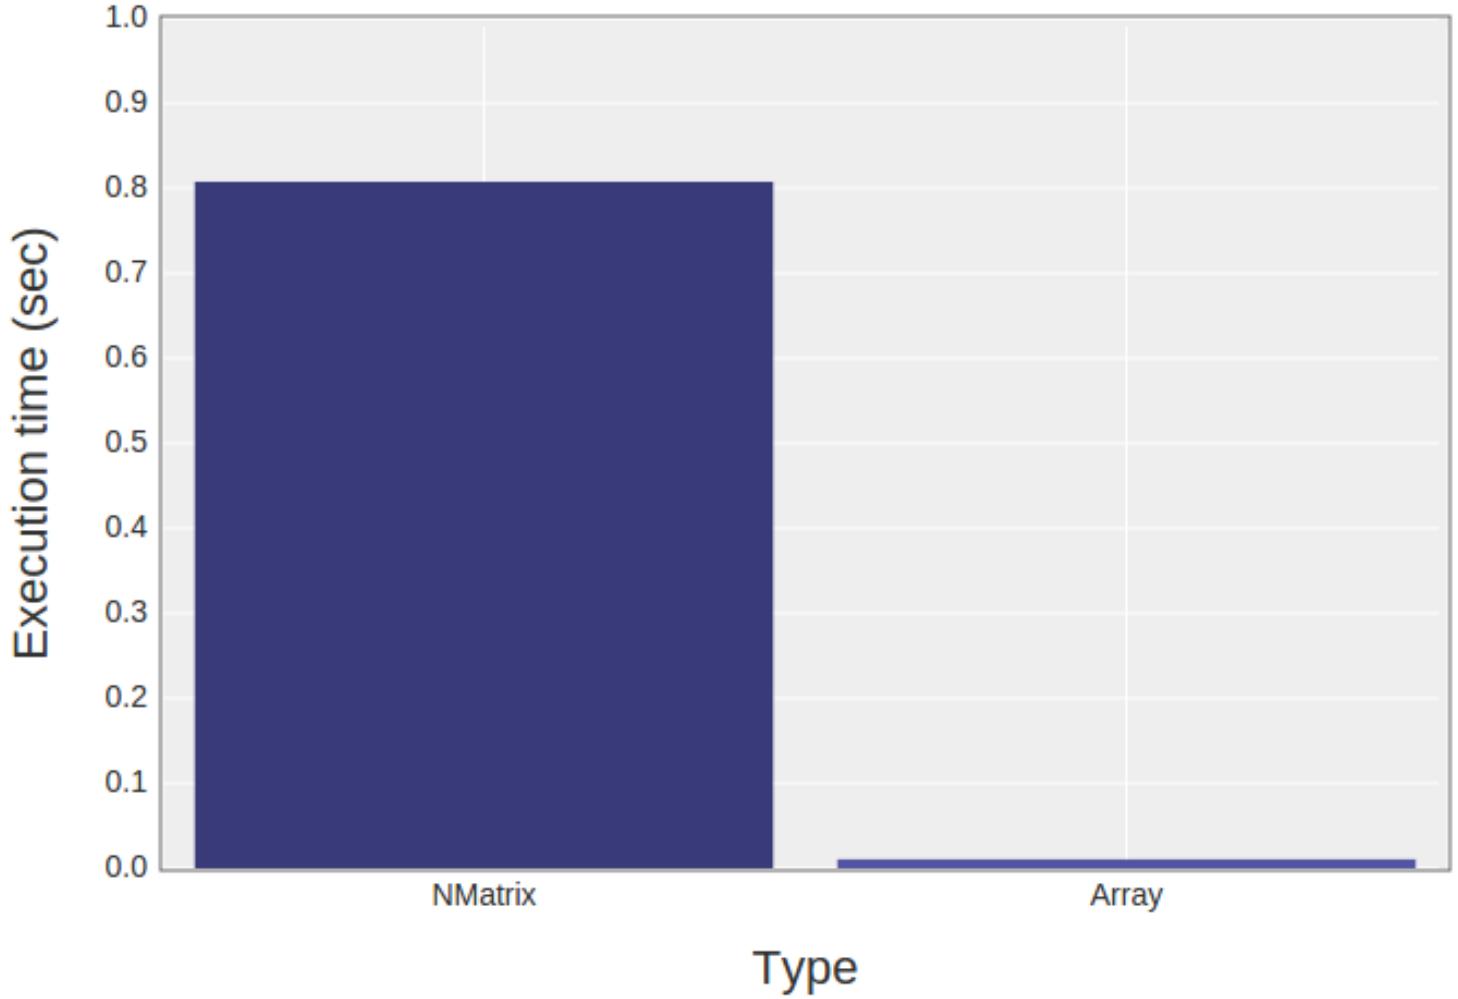

NaCl

多言語との差別化

- **DSLの活用**
  - ブロックの効果的利用
- **Rubyの動的性質の活用**
  - スキーマレスなデータとの親和性

NaCl

DSLの活用提案

- **Daru::DataFrame#where**
  - 現在の記法

```
df.where(df[:x].gt(1))
df.where(df[:x].gt(1) & df[:y].lteg(10))
```

  - 拡張案

```
df.where { :x > 1 }
df.where { (:x > 1) & (:y <= 10) }
```

NaCl

Rubyの言語拡張案

- **ブロック内でのみRefinementsを有効にする**
  - https://github.com/shugo/ruby/tree/eval_using

```
module FixnumDivExt
  refine Fixnum do
    def /(other)
      quo(other)
    end
  end
end

p 1 / 2
instance_eval(using: FixnumDivExt) do
  p 1 / 2
end
p 1 / 2
```

NaCl

デモ

- **Daru::DataFrame#whereの拡張**
  - https://github.com/shugo/DCW2016/blob/master/DaruRefinements.ipynb

NaCl

References

- ジェイムズ・オーウェン・ウェザーオール, *ウォール街の物理学者*, 早川書房, 2015
- M. F. M. Osborne, *Brownian Motion in the Stock Market*, Operations Research, 1959
- Benoit Mandelbrot, *The Variation of Certain Speculative Prices*, Jounal of Business, 1963
- Benoit Mandelbrot, *The Variation of Other Speculative Prices*, Jounal of Business, 1967
- 平岡和幸・堀玄, *プログラミングのための確率統計*, オーム社, 2009
- Wes McKinnery, *Pythonによるデータ分析入門*, オライリー・ジャパン, 2013